隐盾安全智能体 • 正式答辩 5 分钟讲稿（11 页版）

> 版本：**V3.6.20** · 2026-10-22 结构：严格按组委会四段式 ①作品简介 → ②主要功能与预期目标 → ③设计方案及技术实现 → ④创新及应用前景 版式：沿用原稿（顶部四段导航、绿色卡片、黑体标题）；封面/结尾保持原样；创新点拆两页。 用法：每页的「口播」就是 PPT 备注；括号里是动作提示。总口播约 **4 分 40 秒**，留 20 秒缓冲。

---

0. 先背这四句口径（防止再被误解）

1. **脱敏不是模型**：本地正则粗筛 + 程序化精验，27 类实体不调用任何模型。
2. **小模型只做建议**：意图/风险插件是可选建议，不参与放行；关掉不影响脱敏。
3. **云端只看占位符**：映射表不进模型上下文，回答回本机才还原。
4. **exe 不含模型权重**：模型由本机 Ollama 提供，2B/4B 量化模型 CPU 可跑；也可切云端。

---

1. 时间表

时间	页面	章节	口播目标
0:00–0:10	P1 封面	—	报题，不念目录
0:10–0:43	P2 作品简介	①	30 秒讲完背景 + 我们做什么 + 给谁用
0:43–1:10	P3 功能总览	②	三组能力 + 四个目标
1:10–1:57	P4 脱敏对话	②	规则不是模型；占位符往返
1:57–2:40	P5 三层判断审批	③	用途 → 意图 → 操作风险
2:40–3:15	P6 审计黑匣子	③	每次使用都留痕
3:15–3:40	P7 万物皆插件	③	能力可加，判定权不外包
3:40–4:00	P8 控制端	③	集中看掩码事件，策略只能收紧
4:00–4:22	P9 创新（一）	④	网关 + 用途
4:22–4:44	P10 创新（二）	④	laya 适配 + 脱敏知识库
4:44–4:49	P11 结尾	—	一句话收住
4:49–5:00	缓冲	—	不拖堂

4:20 检查点：必须说到 P9。没到就跳过 P7 的展开，直接讲“能力可以加，判定权不外包”，然后进 P8 控制端、P9/P10 创新。

---

2. 逐页口播

P1 封面（10 秒）

> “各位评委好，我们的项目是隐盾安全智能体——面向数据隐私安全的 AI 协同办公桌面智能体。”

（不要念团队成员和目录，直接翻页。）

P2 ① 作品简介（30–33 秒）

> “出发点很直接：涉密办公要用 AI，但敏感原文不能出本机。风险在四个环节：发给 AI 时出网、存到电脑里留副本、历史记录越积越多、AI 动手时未经确认。我们对应四道本地控制：入口脱敏、脱敏日志加加密存储、会话加密加审计、审批加权限。右边是分工：数据先过隐盾内核，模型只收到占位符，回答回本机还原；框架做判定，模型只做推理。”

（手势先点左边四张卡，再沿右侧架构图走：数据 → 内核 → 模型 → 本机还原。）

如果评委追问“AI 怎么脱敏”：立刻纠正——“脱敏不用模型，是本地规则；模型只负责后面的推理。”

P3 ② 功能总览（30–33 秒）

> “先总后分：上面三组能力回答‘能做什么’——对话与资料、文件操作与审计、统一后台；下面四个目标回答‘做到什么程度’——可用，本机 2B/4B 量化模型 CPU 可跑；不可见，已识别实体出网明文 0 例；可审计，工具、审批、还原全部留痕；可部署，提供标准安装包，也保留免安装单文件方便试用。”

（先点“一、三组能力”，横着带过三张卡；再点“二、四个目标”，手指四个绿色色块。）

P4 ② 关键功能：脱敏对话（45–47 秒）

> “先看脱敏对话。用户输入的是姓名、手机号、身份证这些真值；发送前，本地规则先做正则粗筛，再用程序化校验器精验——手机号看位数，银行卡过 Luhn，身份证看 18 位形状与出生日期，带分隔符的形态再过校验位；人名看姓氏表和触发词窗口。**这一步不调用任何模型。** 模型真正收到的是占位符；回答回来，本机再把占位符换回真值。映射表加密、不进模型上下文，所以模型服务方拿到的只是一段占位符文本。对已经识别出来的实体，出网明文是 0 例。”

（指左边“用户看到 / 模型看到”两条；再指右边真实客户端截图和审计预览。）

如果评委问“能不能识别工作秘密”：接“自定义敏感词表（字面词 + 正则）、自定义姓名/通讯录、行业词表插件；项目代号、客户名单、内部术语都能加。”

P5 ③ 三层立体判断：先用途，再意图，最后操作风险（43 秒）

> “三层立体判断：先看用途，再看意图，最后看操作风险。第一层是用途红线，内核确定性规则，在模型和工具之前执行：收集个人信息去出售或牟利，直接拒绝；外发或公开，顶部红色警示。第二层是意图预判，回答想干什么、涉及什么数据、去哪、什么用途，模型只能加重不能减轻。第三层是操作风险，laya 按本机、局域网、正则三级给高/中/低危，并标明来源，只评动作本身。三层都只是建议，放行由人决定。”

（指弹窗顶部红条 → ① → ② → ③；最后指底部红字“是否相符不再发言”。）

如果评委问“为什么有的弹窗没有‘是否相符’”：答“用途触线时故意不发言，避免用‘相符’给危险请求背书；没有触线时会正常给相符/存疑/不符。”

P6 ③ 审计黑匣子：每次使用都留痕（33–38 秒）

> “审计的重点不是‘不可写’，而是每次使用都留痕。每次打开面板都会重新校验 HMAC 链和锚点，徽标不是缓存；现场可以直接点一次盾牌图标验证。每条工具调用、隐私检测、审批决策都在链上；审计里只存脱敏预览。改中间、尾部截断、降级改写、删锚点这些手法都能被发现——可发现是底线；能重写整台机器的人我们挡不住，这一点如实说明。”

（如果现场演示：点左侧盾牌图标，指绿色徽标；不要点“重建锚点”。）

P7 ③ 万物皆插件（25 秒）

> “万物皆插件：能力可以通过插件增加。laya 按本机、局域网、正则三级，每级标明来源，只做建议；插件只有建议型和增强型能力，判定类钩子永久禁止——能力可以加，判定权不外包。”

（三列各指一下，不展开细节。）

P8 ③ 控制端（20 秒）

> “控制端不是新的能力，而是把端点已经落盘的掩码事件集中起来看。它看到的和端点本地审计一样：掩码态、链头、元数据，拿不到真值，也不代理模型流量。策略只能收紧：敏感路径取并集、审批下限取更严，豁免/放行/白名单不在通路里。”

（四张卡片各点一下：态势总览 → 事件台账 → 策略下发 → 统计分析。）

P9 ④ 创新（一）：网关与用途（22 秒）

> “第一个创新是内存级脱敏网关：入口处完成替换，真值只在本机内存，模型上下文只有占位符；对已识别实体，出网明文 0 例。第二个是先判用途再判操作：用途触线时直接拒绝，不调用模型，也不给审批放行机会。”

（指左、右两段 GIF，各停 1 秒。）

P10 ④ 创新（二）：分级与知识库（22 秒）

> “第三个是 laya 决策模型：它是近一个月才火起来的决策模型，我们第一时间接进项目，用它判断动作危不危险；本机优先、局域网次之、正则兜底，只做建议、不参与放行。第四个是脱敏知识库：入库即逐块脱敏，向量库只存占位符，检索结果标注片段不是全文。场景先做律所、医院、制造和政府外包；边界也如实说，控制面还是演示级原型，识别率是经验值。”

（指 laya 设置页与知识库检索 GIF；最后落到右下“边界”。）

P11 结尾（5 秒）

> “隐私保护不该是使用约定，而应是架构约束。谢谢各位评委。”

---

3. 超时删减优先级

从后往前砍，先砍“解释”，不砍“结论”：

1. **P8 控制端的展开**（策略细节/四张卡片）→ 只留一句“控制面只汇总掩码事件，策略只能收紧”。
2. **P3 的四个目标**→ 只留“可用、不可见、可审计、可部署”四个词。
3. **P6 的“六种删改”** → 只说“改中间、尾部截断、降级改写都能发现”。
4. **P4 的规则细节**→ 只留“正则粗筛 + 程序化精验，不调用模型”。
5. **绝不砍**：P5 的三层判断、P4 的“规则不是模型”、P9/P10 的四个创新。

---

4. 彩排检查点

检查点	应该说到	没到怎么办
1:15	P4 脱敏对话	砍 P3 的目标带
2:05	P5 三层判断	砍 P4 的规则细节
2:50	P6 审计	砍 P5 的第二层展开
3:20	P7 扩展	砍 P6 的六种删改
3:40	P8 控制端	砍策略细节，只留“只汇总、只收紧”
4:00	P9 创新（一）	直接跳到 P9，不要回头补
4:22	P10 创新（二）	只讲结论，不再展开场景

三次彩排记录：每次记下到 P4 / P6 / P8 / P10 的时间；第 11 页必须在 **4:47** 前开始，总时长超过 5:00 就按上面的顺序砍。

---

5. 答辩问答

见 预答辩_3分钟_答辩准备.md。正式答辩继续用那 18 题 + 5 道压力题；其中 Q5（小模型/laya）和 Q14（4B 部署）已按“脱敏不是模型、exe 不含权重”更新过口径。