

隐盾安全智能体 · 使用说明

面向涉密办公场景的本地化隐私防护桌面智能体 · V3.3 Yindun Security Agent — 让本地 AI 更安全、更智能、更可控

一、产品简介

隐盾安全智能体是一款常驻桌面的 AI 办公助手，核心差异在于**内置内存级隐私防护**：所有敏感信息（手机号、身份证、银行卡、密钥、病历、金额、人名等）在进入大模型之前，会在内存中自动替换为加密占位符；模型全程只见占位符，回答返回时再自动还原为明文呈现给你。

配合文件沙箱、权限分级、命令白名单、高危操作人工审批与哈希链审计，隐盾把“数据出网、落盘、留痕”三大泄露面逐一关闭，让你放心把涉密文档交给 AI 处理。

典型用途：合同/简历/病历等涉密文档的问答与摘要、本地知识库检索、项目代码分析、办公文件创建与整理、可追溯的操作审计。

二、安装与启动

界面说明：V3.3.2 起隐盾使用 Web 界面（窗口无系统边框，**拖动顶部条即可移动窗口**，右上角有最小化 / 置顶 / 关闭）。左侧是会话列表，右侧是对话区；左下角三个图标分别是 **workflow、审计黑匣子、设置**。

方式 A：免安装单文件 exe（推荐，双击即用）

1. 拿到 隐盾安全智能体_V3.3.2_便携版.exe（约 100+ MB，单文件）；
2. **双击直接运行**——无需安装、无需任何脚本、不需要管理员权限；
3. 首次启动约需 10~20 秒（单文件会先解压到临时目录，属正常现象），之后正常速度。

数据落在哪：配置、会话记录、审计日志、知识库向量数据都写在 **exe 同目录**，所以请把 exe 放在可写目录（桌面、文档、便携盘均可）。**卸载**：删除 exe 及其同目录下生成的数据文件即可，不留残余。

方式 B：源码运行（开发者）

```
# Python 3.10+, 安装依赖
pip install -r requirements.txt
python run.py
```

首次启动若被杀毒软件 / Windows Defender 提示，选择"仍要运行"或添加信任即可（未签名的绿色软件常见误报，源码可自查）。

三、首次使用：配置一个"算力底座"

隐盾需要接入一个大模型作为算力底座，**两种方式二选一**（约 2 分钟）。启动后看界面左上角状态灯：绿色圆点 + 模型名即已就绪；未就绪时点左下角齿轮图标进设置。

方式 A：本地离线模型（推荐，数据全程不出网）

1. 下载安装 Ollama：<https://ollama.com/download>（安装后服务自动运行）；
2. 打开命令行执行，拉取一个支持工具调用的模型：`bash ollama pull qwen2.5:7b-instruct`
如需使用知识库检索，再拉取向量模型：`bash ollama pull nomic-embed-text`
3. 启动隐盾，在设置页"算力底座 → 模型选择"中选中检测到的本地模型。

方式 B：云端模型（无需下载大文件）

1. 点左下角齿轮图标 → 「外部算力（OpenAI 兼容）」→ 填名称 / 模型 ID / 接口地址 / API Key → 添加；
2. 填入任一 OpenAI 兼容 API 的参数（示例：智谱开放平台）：
- `base_url`：`https://open.bigmodel.cn/api/paas/v4`
- `api_key`：你自己的密钥 - `model_id`：`glm-4-flash`
3. 保存后在模型下拉框选择该模型。

隐私提示：开启"隐私隔离网关"（默认开启）时，发往云端的内容已自动替换为占位符，真实敏感数据不出本地。

四、核心功能使用

4.1 对话与隐私脱敏

直接在底部输入框下达指令即可。含敏感信息的内容会先脱敏再交给模型，回答后自动还原。

- **快速 / 思考模式**：输入框上方切换。快速模式为只读安全模式（禁止一切写盘/删除/命令执行）；思考模式支持完整工具调用与多轮推理（思考深度 1-10 在设置页调节）。
- **挂载文件**：点"📎 挂载文件"上传 PDF / Word / Excel / TXT 等，直接在对话中就其内容提问。
- **会话管理**：💬 切换历史会话，➕ 新建会话；多会话相互隔离，记录加密存储。

4.2 本地知识库（脱敏 RAG）

在设置页底部"本地知识库"区，点"➕ 添加文档"将机密文档入库（入库即逐块脱敏，向量库中只存占位符，真实隐私永不落盘）。之后在对话中即可语义检索问答。

4.3 协同工作流

点左下角 workflow 图标进入工作流编排，内置合同审查 / 周报生成 / 代码安全检查等模板，支持步骤执行、审批通过与人工拦截；标记为「演示步骤」的环节目前返回模拟结果（界面已如实标注）。

4.4 审计黑匣子

点左下角 audit 图标打开审计黑匣子：LLM 输入输出、工具调用、脱敏还原、审批决策逐条留痕，哈希链完整性状态实时可见，可导出 JSON / HTML 审计报告；面板内还提供「隐私健康体检」与「模型行为画像」。

五、安全机制说明

机制	作用
隐私 脱敏 网关	27 类敏感实体识别（正则粗筛 + 程序化精验），进模型前占位符化，映射表 Fernet 加密、密钥 DPAPI 保护
文件 沙箱	所有文件操作限定在沙箱目录内，越界读写一律拒绝
权限 分级	完全控制 / 安全只读 / 彻底审计 三档，按需收口写盘能力
命令 白名单	放行 python/pip/git/echo，去 shell 化执行，并做子命令级收口：python 仅允许执行沙箱内的 .py 脚本（ <code>-c</code> / <code>-m</code> / 标准输入等内联代码一律拒绝），pip/git 仅允许只读子命令（install/download/clone/fetch 等会触发代码执行或改动仓库的入口被拒绝）
熔断 审批	高危操作挂起后台线程，弹窗展示申请工具、目标路径与即将执行的命令 / 即将写入的内容，人工二次确认后才放行；超时自动驳回
哈希 链审 计	HMAC-SHA256 链式存储，篡改即告警；审计自身只存脱敏预览

六、数据与隐私

- **配置**：程序目录下 `global_config.json`（模型、权限、界面等；免安装版即 exe 同目录）。
- **会话**：`chat_sessions.json`，内容加密存储。
- **审计**：`audit_logs/`，哈希链防篡改，仅存脱敏预览。
- **知识库**：`data/knowledge_base/`，只存占位符向量。
- 免安装版：删除 exe 与其同目录生成的数据即可；安装版：卸载即清除以上全部本地数据。

七、常见问题 (FAQ)

- **状态栏显示"模型初始化失败"**：未装 Ollama 或未拉取模型，按第三节方式 A 完成，或改用方式 B。
 - **杀毒软件报警**：未签名绿色软件常见误报，添加信任即可。
 - **想让 AI 写文件却提示"快速模式无法执行"**：切到"思考"模式再试。
 - **回答里出现 [PHONE_0_xxxx] 这类占位符没还原**：属跨轮历史占位符，正常会随会话映射还原；若长期不还原，可在设置页关闭再开启"隐私隔离网关"重置会话。
 - **换了电脑/重装系统后旧会话无法还原明文**：脱敏密钥绑定 Windows 用户账户 (DPAPI)，属安全优先于可恢复性的既定设计。
-

八、版本与声明

- 当前版本：**V3.3** (技术栈 Python · LangChain · PySide6 · Chroma · Ollama)
- 本文档中出现的个人信息 (张伟 / 13812345678 等) 均为虚构测试样例，不涉及任何真实个人数据。