隐盾安全智能体 • 使用说明

> 面向涉密办公场景的本地化隐私防护桌面智能体 · V3.6.15 Yindun Security Agent — 让本地 AI 更安全、更智能、更可控

一、产品简介

隐盾安全智能体是一款常驻桌面的 AI 办公助手，核心差异在于**内置内存级隐私防护**： 所有敏感信息（手机号、身份证、银行卡、密钥、病历、金额、人名等）在进入大模型之前， 会在内存中自动替换为加密占位符；模型全程只见占位符，回答返回时再自动还原为明文呈现给你。

配合文件沙箱、权限分级、命令白名单、高危操作人工审批与哈希链审计， 隐盾把"数据出网、落盘、留痕"三大泄露面逐一关闭，让你放心把涉密文档交给 AI 处理。

典型用途：合同/简历/病历等涉密文档的问答与摘要、本地知识库检索、 项目代码分析、办公文件创建与整理、可追溯的操作审计。

二、安装与启动

> 界面说明：V3.3.2 起隐盾使用 Web 界面（窗口无系统边框，**拖动顶部条即可移动窗口**、**沿窗口边缘拖拽可改变大小**， 右上角有最小化 / 置顶 / 关闭）。左侧是会话列表，中间是对话区，右侧是**可折叠的第三栏** （设置 / 审计两个页签）；顶栏两侧各有一个折叠按钮，收起后把空间让给对话。
>
> **三栏宽度可以自由调**：把鼠标移到会话栏右边缘或面板左边缘（会出现一条细高亮线），按住拖动即可改变该栏宽度；**双击手柄**恢复默认宽度；手柄获得焦点后可用方向键微调（按住 Shift 步长更大）。宽度会自动记住，下次打开还是你调好的样子。范围上做了保护： 会话栏 200–420px、面板 300–640px，且**对话区始终保留至少 420px**——窗口变窄时优先收窄两侧， 再窄就自动把右栏收起来（窗口重新变宽会自动放回，这与"你自己手动收起"是两回事，手动收起不会被自动展开）。
>
> **闪发浮条（折叠模式）**：点顶栏的折叠按钮，窗口会缩成一条浮条（贴着原窗口底边、水平居中）。 在浮条里输入指令按回车，会**自动展开完整界面并把指令发出去**；按 `Shift+Enter` 则是**换行不发送** （浮条输入框最多显示两行，再多就在框内滚动）；浮条右侧常显一行状态 （推理中…/已完成），不展开也知道有没有在跑；点浮条左侧的展开按钮或按 `Esc` 即可还原完整界面， 窗口会精确回到折叠前的位置与大小。适合"只想顺手发一句、不想让窗口占地方"的场景。 **草稿不会丢**：主输入框里打好的字在折叠后会跟着进浮条，折叠期间在浮条里打的字在展开后会回到主输入框； 模型正在推理时按回车也不会吞掉你打的字，只会提示"正在推理中"。
>
> **置顶（悬浮于最上层）立即生效**：点右上角的置顶按钮或设置里的「窗口始终置顶」开关， **默认是关闭的**（V3.6.7 起：常驻最上层会挡住别的窗口），开了之后会记住，下次启动仍按你的选择。
>
> 马上生效，不需要重启。

方式 A：免安装单文件 exe（推荐，双击即用）

1. 拿到 `Yindun-Portable-<版本>.exe`（约 140MB，单文件；从 GitHub Release 下载时为此名——资产名不支持中文；本地自行构建时产物名为 `隐盾安全智能体_<版本>_便携版.exe`）；
2. **双击直接运行**——无需安装、无需任何脚本、不需要管理员权限；
3. 首次启动约需 10~20 秒（单文件会先解压到临时目录，属正常现象），之后正常速度。 界面底部会显示启动进度：**探测算力 → 载入模型 → 已就绪**；模型在后台载入内存（本机实测约 7~15 秒， 首次或换模型时可能要 20~60 秒），载入完成后再提问就不会等；载入期间界面已经可以正常操作。

出问题看哪里：运行日志在 **exe 同目录的** `logs/yindun.log`（按 2MB × 3 份轮转，含启动、模型载入、插件与工具调用、异常栈；敏感值写盘前已掩码）。查更细的过程可加 `--log-level DEBUG` 启动；若需要把程序内部的常规输出也一并记下（排障用），再加 `--log-capture-prints`（**默认不采集**：日志是明文落盘面，默认只记关键事件）。 **数据落在哪**：配置、会话记录、审计日志、知识库向量数据都写在 **exe 同目录**，所以请把 exe 放在可写目录（桌面、文档、便携盘均可）。 **卸载**：删除 exe 及其同目录下生成的数据文件即可，不留残余。

方式 B：源码运行（开发者）

```
# Python 3.10+，安装依赖
pip install -r requirements.txt
python run.py
```

> 首次启动若被杀毒软件 / Windows Defender 提示，选择"仍要运行"或添加信任即可（未签名的绿色软件常见误报，源码可自查）。

三、首次使用：配置一个"算力底座"

隐盾需要接入一个大模型作为算力底座。**设置按"数据边界"分成三档**——本机 / 局域网 / 公网， 你随时能看出"这个模型会把数据带到哪里去"：

档位	数据边界	典型形态
本机模型	数据不出这台电脑	本机跑的 Ollama（127.0.0.1:11434）
局域网模型	数据出这台电脑，但不出企业内网	公司内网的推理服务 / Ollama（10.x / 192.168.x）
公网模型	数据出企业内网；送出前内容已在本机脱敏	云端 OpenAI 兼容接口（https://.../v1）

入口：点左下角**齿轮**图标 → 顶栏「**模型接入**」页（左边是三档供应商列表，右边是选中项的配置表单）。

方式 A：本机模型（推荐，数据全程不出机器）

1. 下载安装 Ollama：https://ollama.com/download（安装后服务自动运行）；

2. 命令行拉取一个支持工具调用的模型，需要知识库再拉向量模型：`bash ollama pull qwen3.5:4b ollama pull nomic-embed-text`
3. 回到「模型接入 → 本机模型」，点「重新检测」——检测到的模型会列出来，**点一下就切换**： 左栏列出的本机模型（当前在用的那个带「使用中」标记）**点模型名即切换**，右侧「已检测到的模型」胶囊同样一点即切；两处的「使用中」会当场一起变。

方式 B：局域网模型（公司内网的推理服务）

1. 「模型接入 → 局域网模型」→ 点「＋ 添加局域网模型」；
2. 填 **显示名称 / 模型 ID / 接口地址**（如 `http://10.0.0.8:8000/v1`），内网通常不需要 Key；
3. 点「**测试连接**」——通了会显示该端点提供的模型名，并可自动补进"模型 ID"；再点「保存」。

> 探测是你在这页**显式发起**的动作：地址只取自输入框、不跟随重定向、4 秒超时、只读模型列表。

方式 C：公网模型（云端 API）

1. 「模型接入 → 公网模型」→「＋ 添加公网模型」；
2. 填名称 / 模型 ID / 接口地址 / API Key，先「测试连接」再「保存」。 示例（智谱开放平台）：`https://open.bigmodel.cn/api/paas/v4` + `glm-4-flash`；
3. 保存后在输入框下方的**模型胶囊**里选择它。

> **密钥怎么改、会不会丢**：密钥存下之后**不再回显**（界面只显示「已配置」），输入框留空即 **不动已存的密钥**——改地址、改模型名后直接再点保存即可；只有你**填了新密钥**才会替换。 「测试连接」在留空时也会用**已存的那把密钥**去测，不会因为输入框空着就报「密钥不被接受」。 想彻底清除密钥：删掉这个条目再重新添加。
>
> **隐私提示**：开启"隐私隔离网关"（默认开启）时，发往公网的内容已在本机替换为占位符， 真实敏感数据不出机器；密钥加密存本机、界面不回显。

切换模型

输入框**下方那一行**就是会话级设置（参考主流 agent 的输入区布局）：`＋ 挂载文档 · 模型胶囊 · 思考强度 · 发送`。点模型胶囊会按三档分组列出可用模型； 思考强度是**四档下拉**（低 / 中 / 高 / 最高，对应推理轮次约 2 / 4 / 7 / 10），点一下即生效； 模型胶囊左侧还有一枚**本对话**

权限胶囊（盾牌图标），管的是"这个对话让 AI 做到什么程度"—— 点开可以为本对话单独设档，或选「跟随设置默认」。换模型、换档位、换权限都即时生效，正在跑的轮次不受影响。

四、核心功能使用

4.1 对话与隐私脱敏

直接在底部输入框下达指令即可。含敏感信息的内容会先脱敏再交给模型，回答后自动还原。

- **输入区**（V3.6.15，参考 ZCode 新版）：左下是「+」挂载与**权限胶囊**（本对话生效），右下是**模型名 + 思考档位 + 方形发送键**，整体读作「本机 Ollama / qwen3.5:4b 高 ∨」；推理中模型名左侧出现小转圈，点方形停止键可随时中断。
- **快速 / 思考模式**：输入框上方切换。快速模式为只读安全模式（禁止一切写盘/删除/命令执行）； 思考模式支持完整工具调用与多轮推理（推理强度在输入框下方的「思考」四档控件里随手调：低 / 中 / 高 / 最高）。快速模式同样支持多轮工具调用，只是不强制深化。
- **AI 权限四档**：设置页「隐私与权限 → AI 权限模式」是**新对话的默认档**，四档配一张能力对照表（读取一律放行，差别只在写盘 / 删除 / 执行命令）； 每个对话还可以在输入区的权限胶囊里**单独设档**（例如"整理资料"这个会话放到自主模式、"改代码"那个会话留在变更前确认），覆盖值随会话保存，切回该会话仍在；选「跟随设置默认」即清除覆盖。 计划模式只读分析、不做任何变更；变更前确认为默认档（写盘 / 删除 / 命令前逐次确认）；自主模式在沙箱内自动写盘、删除与命令仍需确认； 完全访问在沙箱内连删除也自动放行。★ **执行命令在任何档位都需要你确认**，系统目录与凭据文件（`.ssh` / `.aws` / `.env` / `id_rsa`）的拦截与档位无关。 切换档位**下一个操作就生效**，不需要重启。
- **严格模式（可选，收紧命令执行）**：设置页「隐私与权限 → 允许执行本地脚本」关闭后，命令执行禁用 Python 等解释器，仅保留只读命令（git 只读 / echo）；需要跑脚本的办公流程再打开。 无论开关如何，命令都在进程容器内执行（超时会终止整棵进程树），且每次执行仍需人工审批。
- **整理文件**（V3.6.8 起可直接指挥）：移动、复制、改名、**批量改后缀**、建目录都有对应工具 —— 例如「把桌面上所有 `.jpeg` 改成 `.jpg`」「把这个文件夹里的报告移到 D 盘存档」「帮我建一个 `素材/截图` 目录」。 ★ 默认可读写范围 = 程序目录 + 你的**桌面 / 文档 / 下载**，所以这些日常操作不再被当成越界； 写盘类操作仍按当前权限档走（变更前确认档会先弹窗给你核对）。两条安全约定：**目标已存在时默认拒绝覆盖** （要覆盖得明确说"覆盖"）、**批量改名遇到重名会整批拒绝**（不会改一半）——工具会把原因和下一步写清楚。
- **挂载文件**：点「+」挂载文件，直接在对话中就其内容提问。**能读到什么格式**（V3.6.7 实测）：

类别	格式	模型能拿到
文档	PDF（文字版）、Word `.docx`、PPT `.pptx`、Excel `.xlsx` / `.xls`	✅ 正文/表格/幻灯片文字（PDF 与 PPT 会标出页码）
文本家族	`.txt/.md/.csv/.tsv/.json/.html/.log/.yaml/.xml/.ini/.conf/.rst`	✅ 原文（自动识别 UTF-8/GBK 等编码）
图片	`.png/.jpg/.bmp/.tif/.webp`	✅ **用 Windows 自带 OCR 读出图上的文字**（离线、不下载模型、一张截图约 0.05 秒；结果里会标注引擎并提示可能存在误差）。非 Windows 或系统缺中文语言包时，会明确告诉你「需要 OCR 组件 / 请给文本版」，**不会假装读到了**
扫描	图片型 PDF	✅ 同上：逐页渲染后

类别	格式	模型能拿到
件 PDF		走 OCR 出字（页码照旧标出）
音频	`.mp3/.wav` 等	❌ 本版**不支持**（转写引擎未随包提供，界面会如实说明）
压缩包 / 其它二进制	`.zip`、未知格式	❌ 明确提示"请先解压/请提供文本版"

上传后每份附件在输入框上方有一个胶囊：读出多少字、是否失败、失败原因、解析来源（内核/插件） 都会显示；读不出来的会**标红并写清原因**。长文档不会一股脑塞给模型——超出预算的部分改为 按题号/关键词检索（模型会自己调 `read_attachment_chunk` 去取），这是为了让小窗口的本地模型 也能处理长文档而不被截断。 - **会话管理**：💬 切换历史会话，➕ 新建会话；多会话相互隔离，记录加密存储。 - **长回答不会半句截断**（V3.6.15）：模型单次生成长度用尽时，界面会自动从断点**接着写一次**并把两段拼成完整回答；如果续写后仍到上限，会明确提示「回复『继续』即可接着写」，不会把半句话当成已完成。 - **请求用途红线**（V3.6.15）：如果指令是「收集/整理个人信息 + 出售、转卖、变现」，智能体会**直接拒绝**（不调用模型、不产生任何文件操作、写入审计）；如果是「收集个人信息 + 发给他人/上传/公开」，仍可在本机整理，但审批弹窗顶部会出现红色用途警示。整理自己的资料（如备份通讯录）不受影响。

4.2 本地知识库（脱敏 RAG）

在设置页底部"本地知识库"区，点"➕ 添加文档"将机密文档入库（入库即逐块脱敏， 向量库中只存占位符，真实隐私永不落盘）。之后在对话中即可语义检索问答。 **入库支持的格式与上表同一套解析器**（文档 / 文本家族 / 图片 / 扫描件都走同一条 OCR 通路 ✅， 音频与压缩包不支

持）；**哪一篇没进库、为什么**都会当场列出来，不会静默少收录。 单文件上限 **50MB**；同名文件重复导入以最新一次为准。

- **知识库只答本机/本单位资料**（V3.6.15）：合同、报表、规章、已上传文档这类问题会先检索知识库；算法、原理、代码、研究类**通用知识**问题由模型直接推理，不会被拽去查库。
- **检索结果给的是片段，不是全文**：每段约 500 字（相邻片段有 50 字重叠），界面/回答里会明确标注「这是检索命中的片段」；相关度按距离换算，命中过弱时会直接说明「知识库里没有这条」，不拿无关片段硬答。
- **同一轮不会反复检索、反复弹审批**：相同查询会复用已有结果；第二次起会提示模型停止重复检索，直接基于已有内容作答。

4.3 协同工作流（界面入口已移除）

> **V3.6.7 起不再提供工作流界面的入口。**评估结论：真实办公里"按预设线性流程一次走完"很少见， 而它没有分支 / 回退 / 单步重跑，写材料、查资料、改代码这类开放任务本就不该塞进固定流程里。 内核的**工作流引擎、模板注册与步骤级审计全部保留**（插件仍可注册模板、审计链里仍能看到 步骤事件），需要时可在后续版本恢复入口；当前用户侧看不到任何工作流入口。

4.4 审计黑匣子

点左下角审计图标打开审计黑匣子：LLM 输入输出、工具调用、脱敏还原、审批决策逐条留痕， 哈希链完整性状态实时可见，可导出 JSON / HTML 审计报告；面板内还提供「隐私健康体检」与「模型行为画像」。 启用「导出格式扩展」插件后，导出菜单还会多出"Markdown 表格 / 卡片式 HTML"两种格式（菜单里会标明来源）。

关于"链校验未通过"：校验未通过时面板会直接写出**原因**（例如"尾部被截断""锚点缺失" "第 N 条出现未受保护的旧版条目"），不是只给一个红叉。若原因是**锚点缺失**——通常出现在 从旧版本升级、或把审计目录拷到另一台机器之后——面板会给出「重建锚点（接受当前链）」按钮： 点它表示**你确认接受当前这份链作为新的信任起点**；确认之后，此前发生的尾部截断将无法再被发现， 所以请先确认这份链确实没有被裁剪过再点。

4.5 插件（按需扩展能力）

设置页「插件（能力扩展）」区列出内置与用户安装的插件，默认全部关闭，需要时打开开关即可。 每个插件卡片会写清：**它提供了什么能力**、来源（内置/用户安装）、网络/文件权限、依赖是否满足。

怎么确认插件真的在工作（三个证据，卡片里直接可见）：

1. **运行状态行**（卡片顶部）：显示"已触发 N 次 · 最近时间 · 正常/出错"。 - `等待触发` = 已启用但还没遇到对应场景（如"审批决策提示"要等审批弹窗出现才运行）； - `未启用` = 开关没打开； - `出错：…` = 最近一次运行失败，原因直接写在卡片上。

   > 说明：运行状态只统计"实际被调用过"的次数——不写日志、不猜，有没有干活一眼可见。

2. **效果证据**：插件生效时结果会出现在具体位置——审批弹窗里的提示行（标注了插件名）、导出菜单里的插件格式、工作流引擎的模板列表里的"插件"来源标注（界面入口已移除，引擎保留）。
3. **审计记录**：启用/停用与配置改动都会写入审计页，可随时回溯。 如果怀疑"启用了却没反应"，点「插件自检」——钩子函数缺失这类问题会被直接报出来。

- **自定义敏感词表**：把项目代号、内部称谓、专用术语纳入脱敏。编辑词表文件，每行一条：普通词按字面匹配，`re:` 开头按正则，`#` 开头是注释。命中后送模型的是占位符，还原仍只在本机完成。
- **扩展附件解析**：让 `.eml` / `.html` / `.mht` 也能当附件挂载（纯标准库解析，不联网）， 解析出的文本与内核路径一样先脱敏再送模型。
- **办公工作流模板包**：给工作流补两个模板（代码安全体检增强版 / 本周工作总结）。 其中"导出报告"这类高危步骤的审批由**内核强制**，插件无权降低审批强度。
- **导出格式扩展**：审计报告导出 Markdown 表格、工作流报告导出卡片式 HTML。
- **审批决策提示**：审批弹窗出现后，用本地模型判断"这次操作与你刚才的请求是否相符"，结论异步补发到弹窗，仅供参考。
- **laya 风险分级**：审批弹窗再补一行风险分级（高危/中危/低危）。 **接入三步**：① 命令行 `pip install laya`（约 2~3GB，含 torch；仅源码运行模式可接入， 打包版 exe 因环境隔离无法加载，会自动使用正则回退）；② 设置页打开该插件开关； ③ 首次触发会联网从 Hugging Face 下载模型权重（涉密环境请预先离线导入）， 下载期间插件只等 25 秒就先用正则规则给出提示，权重就绪后自动切换为模型打分。 没装 laya 也完全可用——自动回退到正则规则分级，默认规则开箱自带，`risk_rules.txt` 可在设置页直接编辑、改动立即生效；`backend.txt` 可强制只用模型或只用正则。 无论哪条路径，提示都写明本次来源。

安全说明：插件是**本地代码**，隐盾不会联网下载插件（laya 是你要自己安装的第三方 Python 包）；启用/停用、词表改动都会写入审计。

> 想自己写插件？见 插件开发.md：钩子契约、安全边界与最小示例都在里面。

4.6 企业控制面（员工机自助接入 + 管理员集中管控）

员工侧（三步，不需要管理令牌）：向 IT 要一个 **6 位配对码** → 「设置 → 企业控制面」填 控制面地址 + 配对码 → 点「接入」，然后打开"上报"开关并（可选）打开"定时同步"。 接入后本机只上传**掩码事件与元数据**；控制面下发的策略**只收紧**，已生效的规则会逐条列在这页， 也可以显式撤销。断开上报**不会**自动移除已下发的规则（避免"悄悄放松"）。

控制台侧：顶栏「配对码」生成一次性码；端点表显示**在线/失联**与**策略待同步**； 「导出 CSV」把掩码审计导出来（合规留档，Excel 直接打开）。

对话流里看得见过程：思考（带耗时）、工具动作（名称/目标/结果）、以及**关键判定**—— 隐私隔离网关识别了哪些实体、laya 风险分级的结论等，都直接显示在对话流里，不只在审批弹窗一闪而过。

4.6 控制面（企业侧集中管理，运维用）

给 IT/安全管理员用，普通使用者不需要碰。**默认关闭**——集中管理是显式选用的能力，程序绝不静默上报。

在管理机上启动控制面：

- **便携版（推荐）**：双击 `dist/隐盾控制端_<版本>_便携版.exe` → **直接打开一个控制台窗口并自动登录**， 不需要抄地址、也不需要手输令牌（令牌仍保护远程访问；窗口只在本机回环打开，且页面会立刻把它从地址栏抹掉）。 关掉窗口即停服。**exe 不再带命令行黑窗**（V3.6.7 起）：启动信息（监听地址、数据目录、令牌文件路径） 写在 exe 同目录的 `logs/yindun.log`；若启动失败（例如端口被占），会弹一个系统对话框写明原因与日志路径—— 不会出现"双击了却什么都没发生"。已经有一个控制台在跑时，再双击会**明确提示「已经在运行」并退出** （避免两个实例抢同一端口，让你看到旧版本的界面）：请用已经打开的那个窗口，或先在任务管理器里 结束旧的 `隐盾控制端…便携版.exe` 进程。
- **源码/服务器**：

```
python -m yindun.control              # 起服务 + 开桌面窗口（默认）
python -m yindun.control --no-window  # 只起 HTTP 服务：装到服务器上、由别人用浏览器访问
python -m yindun.control --browser    # 不弹窗口，用系统默认浏览器打开
python -m yindun.control --host 0.0.0.0 --window yes   # 对外监听（默认不弹窗口，需显式
```

管理令牌在 `control_data/admin_token.txt`（数据库里只存哈希）。远程用户用浏览器打开 `http://<控制面>:8787/`，粘贴令牌即可进入（令牌只留在当前标签页，关闭即清除）。

让别人的机器连进来（例如和同学组局域网一起看）：

1. 控制台右上角点「**配对码**」→ 打开浮窗。里面有三件事：当前配对码（可**自定义**成好念的串，如 `BANJI-2026`；也可一键重新生成）、有效期、以及**局域网地址**（如 `http://192.168.96.148:8787/`）。
2. 浮窗里打开「**允许局域网访问**」开关。控制端默认只监听本机（`127.0.0.1`），**不打开这个开关，别人一定连不上**——这不是网络问题、也不是配对码问题。打开后监听立刻切换，**不用重启程序**，端口不变（别人抄走的地址不会失效）。
3. 如果 Windows 防火墙弹出询问，**必须选「允许访问」**；没弹或之前拒绝过，需要到防火墙里放行（否则地址对、码对，照样连不上）。
4. 把「地址 + 配对码」发给对方：对方浏览器打开地址 → 输入配对码即可进入（配对码**用后即作废**，一张码给一个人）。装隐盾客户端的机器则在「设置 → 企业控制面」里填地址与配对码自助接入。
5. 不用了就关掉开关（切回仅本机）；局域网地址随即可连不上——这是真关，不是只改显示。

> 装着 VMware/VirtualBox 或内网穿透的机器会列出多个地址，**优先用第一个**（通常是 WiFi/热点的），`192.168.x.1` 这类多为虚拟网卡，别人连不上。**安全边界**：对外监听形态**不带 TLS**，只在你自己可信的局域网里用（手机热点、宿舍网这类），不要在公共 WiFi 上长期开着；配对码一次性、管理令牌不要外发。要长期对外提供服务，请按 §4.6 的命令行方式挂在 TLS 反向代理之后。

控制台六页：**态势总览**（在管端点 / 事件总量 / 高危事件 / 链告警 + 链锚定状态 + 告警流）、**统计分析**（近 14 天趋势柱图，深色段为高风险；事件类型 Top 12；级别构成；端点活跃度；近 7 天与环比）、**事件台账**（按端点/类型/级别/关键词检索）、**端点资产**（版本、链长、模型、插件、严格模式、生效策略）、**策略下发**（只提供"收紧"语义的四类输入）、**模型用量**（调用计数与交互体量，不含内容）。统计口径全部在服务端聚合（界面只拿到分页事件，自己算总数会对不上），缺事件的日期补 0 柱，横轴按真实天数铺满——不会把"周末没人用"画成"一直在涨"。支持明暗双主题、10 秒自动刷新、`/` 聚焦搜索、`1`~`6` 切页、`R` 刷新。

在员工机器上接入（端点侧）：

1. 在控制台所在机器上登记端点（需要管理令牌），拿到**端点令牌**与**策略签名密钥**：

```
bash curl -X POST http://<控制面>:8787/api/v1/enroll \ -H "Authorization: Bearer <管理令牌>" -H "Content-Type: application/json" \ -d '{"name":"财务部-27号机","endpoint_id":"ep-fin-27"}'
```

2. 把返回的两个值写入端点配置并启用（`ControlReporter.configure(url, endpoint_id, token, policy_key)`； 令牌会加密落盘）。此后每次上报成功或失败都会写入**本地审计**（事件类型 `control_report`）， 使用者可在审计面板看到"什么离开了这台机器"。

三条边界（选它之前请先读）：

- **控制面拿不到明文**：它收到的内容 = 端点本地审计落盘的内容（敏感路径已掩码为占位符）； 映射密钥由端点 DPAPI 托管，控制面即便拿到映射表也解不开；模型提示词与回答从不经过控制面。
- **策略只能收紧，不能放行**：可下发项只有 敏感路径（并集）/ 审批下限（取更严）/ 允许的模型与插件（交集）/ 强制严格模式； `anonymize`、`bypass`、`auto_approve`、`whitelist`、 `disable_audit` 这类键会被**整包拒绝**——端点被攻破最多让端点管得更严，放行不了任何操作。
- **不是系统级 DLP**：只覆盖隐盾自己经手的文件与命令事件，不监控整机行为；也不代理模型流量。

> 现状声明：这是**演示级原型**——默认只监听回环、单一管理令牌、无多租户与 TLS、无速率限制， 端点侧也还没有定时上报调度器。要对内网正式提供服务，请先补上 TLS 反向代理与来源限制。

4.8 插件：市场里开关，设置栏里配置

设置页「插件」只管两件事：**有哪些插件、开不开**。页面顶部是搜索框，下面按分类（安全 / 文档 / 办公 / 导出） 排成双列卡片，每张卡片是**拼图图标 + 名称 + 版本 + 一句话 + 启用开关**；点「…」展开详情可看 **运行状态**（是否真的被触发过）与**能力清单**。

插件的配置不在这里改，而是各归各位：

1. 打开某个插件的开关（启用）；
2. 如果它有专属设置（例如「自定义敏感词表」的词表、「laya 风险分级」的三级接入）， 左侧设置栏会**新出现「插件」分组与它的栏目**，进去才是它的设置正文；
3. 关掉开关：栏目立刻隐藏，插件能力同时被收回（不是"界面藏起来、实际还在跑"）。 如果当时正停在它的设置页，会自动退回插件页并提示。

插件只能做加法：补充识别、扩展解析、工作流模板、导出格式；脱敏豁免 / 白名单 / 审批放行 / 审计写入永不开放。

4.9 laya 风险分级（可按数据边界分三级接入）

先到插件页**启用「laya 风险分级」**，左侧设置栏的「插件」分组里就会出现它—— 这是 laya 的接入页，与「模型接入」同一套思路——**同一能力，不同数据边界**：

档位	数据边界	需要准备什么
本机 laya 模型	数据不出这台电脑	本机装好 laya（`pip install laya`，依赖 torch）；首次可能需联网下载权重，涉密环境请预先离线导入
局域网 laya 服务	出机器、不出企业内网	公司内网部署的 laya 服务，暴露一个 OpenAI 兼容端点（`/chat/completions`）
正则规则（回退）	全离线	什么都不用装，规则可在本页直接编辑

页面顶部会显示**当前实际生效的是哪一级**与最近一次分级的来源；选中某一级后右侧是它的配置表单： 本机档可以「重新检测」，局域网档填地址与模型名后可以「**测试连接**」（只读探活）与「**试打分**」（真发一次分级请求并把结果回显给你看——"能连上"和"能分级"是两件事，页面不会把前者说成后者）。 无论哪条路径，审批弹窗里的提示都会写明**本次来源**。laya 只影响提示文字，**不参与放行判定**。

五、安全机制说明

机制	作用
隐私脱敏网关	27 类敏感实体识别（正则粗筛 + 程序化精验），进模型前占位符化，映射表 Fernet 加密、密钥 DPAPI 保护
还原与审计口径	回答返回前把占位符换回真值：① 精确匹配；② 模型丢了方括号时按「类型 + 随机码」**容错还原**（不唯一就保留占位符，绝不猜错值）；未能还原的处数会在回答里如实提示，审计也只统计**真的替换掉**的条数（不拿映射表条数充数）。
文件沙箱（可读写范围）	沙箱是**默认可读写范围**（设置页「隐私与权限 → 可读写范围」可改）。**默认范围 = 程序所在目录 + 你的桌面 / 文档 / 下载**（V3.6.8 起；这三个目录按系统外壳的真实路径解析，OneDrive 重定向过的机器也能认对。显式选了目录就**只认它**）。**范围内的操作**按当前权限档走，不受额外打扰；**范围外**（例如 D 盘某个资料目录）不再一刀切拒绝，而是**按档位判定**——计划档拒绝、变更前确认档逐次弹窗（显示完整真实路径）、自主/完全访问档放行，**并且每一次范围外操作都写进审计**、工具结果里也会明写「本次操作在可读写范围之外：<路径>」，对话流里看得见。**与档位无关的硬地板**：系统目录（如 `C:\Windows`）任何档位都拒绝，凭据/密钥类路径仍需确认。符号链接/junction 逃逸照旧拦死（realpath + commonpath 双校验）
权限四档	计划模式 / 变更前确认 / 自主模式 / 完全访问：决定「要不要人工确认」，覆盖**本机文件操作**与**可读写范围之外**的操作（后者一律额外留审计）。**不决定底线**——执行命令四档皆需确认（计划模式拒绝）、系统目录 deny 与凭据路径 confirm 与档位无关、控制面与自定义规则只能更严
命令白名单	放行 python/pip/git/echo，去 shell 化执行，并做子命令级收口：python 仅允许执行**沙箱内**的 .py 脚本（`-c` / `-m` /标准输入等内联代码一律拒绝；脚本路径经 realpath 校验，符号链接/盘符相对路径等越界形态拒绝；子进程只保留基础环境变量）；pip/git 仅允许只读子命令；审批弹窗会展示脚本内容预览，供放行前核对。命令在**进程容器**内执行（Windows Job Object：超时/应用退出即终止整棵进程树，进程数上限 64），并可在设置页开启严格模式直接禁用解释器。**边界说明**：这是策略层控制 + 进程容器，不是完整 OS 级沙箱——放行的脚本仍以当前用户权限运行
熔断审批	高危操作挂起后台线程，弹窗展示申请工具、目标路径与即将执行的命令 / 即将写入的内容，人工二次确认后才放行；超时自动驳回。V3.6.15 起，审批建议先显示「正在研判」占位，结果异步补上，弹窗不再抖动

机制	作用
请求用途合规（V3.6.15）	在模型与工具之前做**确定性**用途判定：收集/整理个人信息 + 出售/转卖/变现 → **直接拒绝**（不调用模型、不产生任何工具操作、写审计）；收集个人信息 + 发给他人/上传/公开 → 允许本机整理，但审批弹窗顶部显示**红色用途警示**。审批弹窗里的「操作意图预判」（可选插件）先说明意图/数据/去向，再让「是否相符」「操作风险」两条建议发言；后两条在红线命中时不再给出「相符」「低危」这种可能被误读为背书的结论
哈希链审计	HMAC-SHA256 链式存储，篡改即告警；另设 HMAC **链锚点**（条数+链头，存放于密钥旁的用户目录）以发现"整链改写"与"尾部截断"；审计自身只存脱敏预览

六、数据与隐私

- **控制面（可选，默认关闭）**：`control_data/`（控制面自己的数据：SQLite 库、管理令牌明文文件）。 端点的上报配置在 `config/control.json`，其中令牌与策略签名密钥**加密落盘**。⚠ 启用前请确认数据边界：控制面看到的内容**等于端点本地审计落盘的内容**（敏感路径已掩码）， 映射密钥始终留在端点（DPAPI 绑定），控制面**无法还原明文**；模型提示词与回答**不经过控制面**。
- **配置**：程序目录下 `global_config.json`（模型、权限、界面等；免安装版即 exe 同目录）。
- **会话**：`chat_sessions.json`，内容加密存储；附件全文同样以密文段存储，**删除会话即连同其附件快照一并清除**（启动时也会把历史遗留的明文会话主动重写为加密存储）。
- **审计**：`audit_logs/`，哈希链防篡改，仅存脱敏预览。
- **知识库**：`data/knowledge_base/`，只存占位符向量（元数据只留文件名，不写本机路径）。
- **用户目录**（`%APPDATA%\Yindun\`）：只有两样东西——脱敏主密钥（Windows DPAPI 按当前用户保护） 与**审计链锚点**（`audit_chain.anchor.<审计目录指纹>.json`，用于发现"整链改写/尾部截断"）。 这两样刻意放在用户目录而不是程序目录：**不能与它们要保护的数据同盘**，否则"删掉密钥/锚点" 就能绕过保护。也因此它们不随 exe 移动（换机器后旧审计链需要重新确认，见 4.4）。
- 免安装版：删除 exe 与其同目录生成的数据即可；如需彻底清除，再删除上述用户目录下的 `Yindun\` 文件夹。 安装版：卸载即清除程序目录数据，用户目录同上。

七、常见问题（FAQ）

- **状态栏显示"模型初始化失败"**：未装 Ollama 或未拉取模型，按第三节方式 A 完成，或改用方式 B。
- **杀毒软件报警**：未签名绿色软件常见误报，添加信任即可。
- **想让 AI 写文件却提示"快速模式无法执行"**：切到"思考"模式再试。
- **回答里出现 `[PHONE_0_xxxx]` 这类占位符没还原**：属跨轮历史占位符，正常会随会话映射还原； 若长期不还原，可在设置页关闭再开启"隐私隔离网关"重置会话。 ★ 若模型把占位符改写成不带方括号的裸形式（例如写在反引号里），内核会**按类型 + 随机码做容错还原**；只有当对应关系不唯一时才保留原样，并在回答末尾如实写「有 N 处占位符未能还原」——宁可不还原，也不猜错值。
- **知识库导入 Excel/PDF 提示「入库完成」但列表还是空的**：本版起不会再出现——入库结果按**真实统计** 显示（「成功 x/y」），失败的每一个文件都会在知识库列表上方**一直显示原因**（例如「Ollama 未在线、 没有拉取 nomic-embed-text」）。如果「添加文档」是灰的，说明本机 embedding 还没就绪，按提示先 `ollama pull nomic-embed-text`。
- **让它生成 Word / Excel / PPT 文件**：直接说「创建一个 aaa.docx，把内容写进去」即可，内核会生成**真正的** Office 文档（Word / WPS / Excel 能直接打开，不是改后缀的文本）；在已有文档上追加或替换内容也仍然可打开。 若本机缺少生成组件，会如实告知并建议改用 .txt，**不会**产出一个打不开的假文件。
- **写进文件的内容里出现 `[PHONE_0_x]` 这类占位符**：属异常——正常会在落盘前还原成真值（跨轮掩码也支持）。 若真的还原不了，回答与状态行都会明确写「有 N 处占位符未能还原」，可在审计面板核对本轮映射。
- **回答只有半句话就显示"已完成"**：本版起内核会识别这种"刚起头就断掉"的输出（很短、且没有句末标点）， 自动让模型**重写一遍完整回答**；重写后仍是断句时，回答末尾会明确标注「模型这次输出疑似被截断」并建议换更大的模型—— 不再把半句话当作正常完成。
- **换了电脑/重装系统后旧会话无法还原明文**：脱敏密钥绑定 Windows 用户账户（DPAPI），属安全优先于可恢复性的既定设计。

八、版本与声明

- 当前版本：**V3.6.15**（技术栈 Python · LangChain · pywebview/WebView2 · Chroma · Ollama；Qt 已移除）

- 插件体系：内核不可插件化（脱敏 / 审批 / 审计 / 沙箱），能力可插件化（识别 / 解析 / 模板 / 导出）， 插件只能"做加法"；详见 插件开发.md。
- 本文档中出现的个人信息（张伟 / 13812345678 等）均为虚构测试样例，不涉及任何真实个人数据。