



隐盾安全智能体

面向涉密办公场景的本地化隐私防护桌面智能体

YINDUN SECURITY AGENT — A Privacy-Gateway Desktop Agent for Confidential Office Work

摘要

大模型进入办公场景面临一个根本矛盾：待处理数据越敏感，越需要模型的能力，却也越不能让其跨越本地边界。本工作报告提出并实现隐盾安全智能体，其核心是一个内存级隐私脱敏网关——将敏感文本在进入模型前形式化地映射为占位符文本与一份加密映射表，使模型在信息论意义上无法接触真实敏感值，同时保持任务可用性。系统配套本地沙箱、命令白名单、高危熔断审批与 HMAC 哈希链审计，构成覆盖“输入—推理—执行—落盘—审计”的纵深防御。为量化隐私防护效果，我们构建了可复现的攻防评测：在 13 篇含 41 个敏感实体实例的合成办公语料上，黑盒出网脱敏召回率 **100%**、明文泄露 **0**、业务数字误报率 **0%**、还原正确率 **100%**；还原劫持攻击 500 轮成功 **0**；提示注入下模型可见明文 PII **0**；白盒持久化与审计产物明文命中 **0**。结果表明该机制在既定威胁模型下能有效阻断敏感数据的出网与落盘泄露。

系统

隐盾安全智能体

版本

V3.4.5 (2026-10)

技术栈

Python · LangChain · pywebview/WebView2 · Chroma

目录

1 研究背景与动机

2 关键挑战

3 系统概览与架构

4 隐私保护机制

5 攻击实验与结果

6 纵深防御与审计

7 安全工程闭环

8 测试与质量保障

9 结论与展望

1 研究背景与动机

大模型办公助手正在快速普及，但企业与机构在涉密文档（合同、薪酬、病历、客户资料）处理上面临一个根本矛盾：**数据越敏感，越需要 AI 的能力，却也越不能把数据交出去**。无论是调用云端 API，还是把对话写入本地日志、向量库与审计文件，每一个跨越本地边界的环节都可能成为泄露面。

现有的通用做法存在结构性缺陷。"提示用户不要粘贴敏感信息"依赖人的自觉而不可靠；"整体关闭联网"则牺牲了云端强模型的能力。二者都没有把隐私保护变成系统本身的属性。我们的出发点是：**把隐私保护从"使用约定"下沉为"架构约束"**——让大模型在物理上"看不见"敏感数据，却依然能把活干完。这既保留了可用性，又从机制上消除了泄露面。

围绕这一目标，我们把办公智能体的泄露面归纳为四类，并逐一设计防线：

出网面

敏感明文随 prompt 发往云端，离开本地即失控
→ 脱敏网关。

落盘面

会话记录、向量库、摘要把真实隐私写进磁盘 →
加密映射 + 入库即脱敏。

留痕面

审计日志本为追溯，却可能反成二次泄露源 → 审计只存脱敏预览。

执行面

智能体具备写盘/删除/执行能力，被诱导即造成物理破坏 → 沙箱 + 白名单 + 熔断审批。

2 关键挑战

把上述目标做成一个可用的系统，需跨越四道核心挑战：

其一，可用性与不可见性的张力。若把敏感值简单删除，模型会因上下文断裂而无法作答。必须在"抹去真实值"与"保留语义结构"之间取得平衡——这正是我们采用占位符化而非删除的设计动机：占位符保留实体类型与位置信息，使模型仍能理解"这里有一个手机号"并据此组织回答。

其二，识别的召回与精确难以两全。中文办公文本里，手机号、身份证、银行卡、人名、金额形态多变（全角、分段、国际前缀、单位混排），既要高召回不漏，又不能误伤订单号、版本号、日期等业务数字。我们以"正则粗筛 + 程序化精验"两段式应对。

其三，防护必须贯穿全链路，而非只在入口。脱敏若只做在用户输入，落盘的会话、审计、向量库、以及模型输出的还原环节仍会泄露；任一环节旁路，整体即失效。这要求把同一套脱敏管线强制施加到所有数据出入口。

其四，可证明性。"隐私有效"不能靠宣称，需要在明确的威胁模型下、以可复现的攻击实验来度量。这驱动我们设计了第 5 节的攻防评测。

3 系统概览与架构

系统采用「GUI 层 — 推理引擎层 — 安全内核层」三层解耦。安全内核由隐私引擎、策略引擎、密钥管理、审计日志四个独立模块组成，可脱离 GUI 单独测试与评测。数据在系统内的旅程为：

用户输入 x → 脱敏 $\hat{x}$ → ReAct 推理 / 工具调用 → 结果脱敏 → 还原 $D(\hat{y})$ → 呈现用户

其中模型侧全程只接触 $\hat{x}$ 与占位符化的工具返回；每一环节的事件均同步写入哈希链审计。算力支持本地 Ollama（数据不出网）与 OpenAI 兼容云端（出网内容已脱敏）双模式。

隐盾安全智能体 · 核心数据流与安全防线




图 1 核心数据流与安全防线：脱敏网关位于输入/输出两侧，安全内核覆盖执行与审计全程

3.1 内核不可插件化，其余皆可插（V3.4 新增）

把能力做成插件，是"让系统长大"的常规做法；但对安全产品，它同时是最危险的改造——一旦脱敏豁免、命令白名单、审批放行、审计写入这些判定权可以被第三方代码接管，"安全"本身就不再由我们掌握。因此我们把边界画在能力性质上，而不是画在模块归属上：

层	内容	是否可插件化
安全内核	脱敏网关、策略白名单、审批放行、审计哈希链、沙箱 文件工具、模型接入	✗ 永不开放（判定权不可外包）
能力扩展	补充识别敏感实体、扩展附件解析、 workflow 模板、导出格式、审批决策提示	✓ 开放，且只能"做加法"

表 2-1 内核 / 插件的边界（按能力性质划分，而非按模块归属）

"只能做加法"不是口号，而是逐条落在代码里的可验证约束：

- **识别只增不减**：插件通过 `register_extra_recognizer` 追加命中区间，内核会复核每一条（越界 / 超长 / 跨行 / 重叠 / 超量丢弃），实体类型强制加 `PLUGIN_` 前缀；内核不存在"让某段内容免于脱敏"的入口——插件写坏了最坏结果是"这条没生效"，不会造成泄露，也不可能造成豁免。
- **模板不降审批**：插件贡献的 workflow 模板由内核注册，高危步骤（写盘 / 删除 / 执行命令 / 导出文件）一律强制人工审批，插件声明 `auto` 也会被纠正并在界面标注"审批由内核强制"；模板 id 不得覆盖内核模板，未知工具整条拒绝。
- **内核兜底不可顶替**：导出格式名（`json/html/md/docx`）为内核保留，插件占用即拒；附件解析只在"内核本来不支持的格式"上优先，内核原生格式（PDF/Word/Excel/文本/音频）始终以内核为准。

- **能力跟着开关走**：每次启停插件都重算能力集合（注销模板、摘除识别器），审计详情记录注册/注销明细——"界面显示已停用、实际还在生效"在架构上不允许出现。
- **不允许静默失效**：钩子函数名与钩子名不一致时不再静默跳过，而是记为错误；界面提供**插件自检**逐个确认声明的钩子都有同名实现；配置文件读不出来必须告警（识别类插件的静默失效等于"以为在保护、实际没保护"）。

工程实现上，内核只暴露两个"只增不减"的扩展点（`core/privacy_engine.py` 的追加识别器注册表、`core/workflow.py` 的外部模板注册），其余能力（解析优先级、导出分发、能力同步）由服务层编排；`yindun/core/` 不认识插件，插件契约集中在 `yindun/plugins/host.py`（钩子清单 + 载荷净化 + 禁用能力黑名单 + 依赖门禁 + 超时隔离）。随包内置 5 个插件（自定义敏感词表 / 扩展附件解析 / 办公 workflow 模板包 / 导出格式扩展 / 审批决策提示），全部默认关闭、按需启用。

4 隐私保护机制

4.1 脱敏算法的形式化定义

设文本全集为 $\mathcal{X}$ ，敏感实体识别器 $\mathcal{E} : \mathcal{X} \rightarrow 2^{\mathcal{X}}$ 输出文本中的敏感实体集合。隐私网关定义为一个随机化映射：

$$A_k : \mathcal{X} \longrightarrow \hat{\mathcal{X}} \times \mathcal{M}, \quad A_k(x) = (\hat{x}, M), \quad M = \{p_i \mapsto \text{Enc}_k(e_i)\}_{e_i \in \mathcal{E}(x)}$$

其中 $\hat{x}$ 是将每个实体 e_i 替换为占位符 p_i 后的文本（送入模型）， M 为映射表，真实值以密钥 k 下的 Fernet 密文存储。占位符形如 $p_i = [\text{Type}_{i_}i_r_i]$ ， $r_i \leftarrow \{a-z, 0-9\}^4$ 为随机 nonce。还原算子 D_k 将输出中的占位符解回明文：

$$D_k(\hat{y}, M) = \hat{y} \prod_{p_i \in M} [p_i \leftarrow \text{Dec}_k(M[p_i])]$$

系统在既定威胁模型下主张四条性质：

- **机密性 (Confidentiality)**：对任意 $e \in \mathcal{E}(x)$ ， $\Pr[e \subseteq \hat{x}] = 0$ ——模型侧无明文（实验 5.2 测得 41/41 满足）。
- **可逆性 (Recoverability)**： $D_k(A_k(x)) = x$ （实验 5.2 还原正确率 100%）。
- **还原不可伪造 (Unforgeability)**：攻击者在不掌握 M 时构造命中他人映射的字面量，成功概率受 nonce 空间约束 $\Pr[\text{collide}] \leq 36^{-4} \approx 5.9 \times 10^{-7}$ （实验 5.4 劫持 0/500）。
- **持久化机密 (Persistence-Confidentiality)**：无密钥 k 时，磁盘产物 $\hat{x}, M, \text{Audit}, \text{Vector}$ 均不可恢复明文（实验 5.5–5.8 命中 0）。

性质边界（诚实声明）：本机制是确定性脱敏而非差分隐私，不主张对"未被规则覆盖的实体类型"或"可由背景知识重识别的属性组合"提供保证；人名识别依赖上下文触发词，无触发词的连续人名列举可能漏检；算法精验（Luhn / 校验位）会主动放过非法格式数字，属"宁漏不误伤"的既定取舍。

第二轮红队另发现并已修复两类**实现层缺陷**（不属机制边界）：替换未按命中位置定位导致同串错位漏脱敏、人名窗口会把字段标签首字吞入（如"张伟电"）；修复后回归复测：正样本泄露 0、负样本误伤 0（阈值 0）。

执行沙箱边界（V3.4.5 更新）：命令执行是策略层控制（白名单 + 子命令级收口 + 脚本 realpath 沙箱归属校验 + 子进程环境收敛 + 人工审批 + 审计）叠加**进程容器**（Windows Job Object：句柄即杀——应用退出/超时即终止整棵进程树，进程数上限 64），并可选**严格模式**直接禁用解释器（仅留只读命令）；**仍不是 OS 级隔离**——被放行的 .py 脚本以当前用户权限运行，理论上仍可触达沙箱外资源；需要更强隔离时应配合系统级方案（受限账户/虚拟机）。

可还原性缺陷（V3.4.5 修复，属实现层）：真实格式文档评测发现——anonymize 的后续规则运行在"已含占位符"的文本上，可能命中占位符内部或跨越其边界（如 ADDRESS 分支把 [BANKCARD_0_xxxx] 订单号 尾段当地址），产生交叉替换使真实值无法还原；现已把占位符改为对后续规则**不透明**（仅在非占位符片段上匹配），并修复银行卡尾部吞换行，回归断言"脱敏→还原逐字一致"（随机 nonce 采样）。

评测口径边界（V3.4.4 补充声明）："召回 100%、泄露 0"只对仓库内评测集（合成办公语料 + 格式变体对抗集 + 8 种真实格式文档集）成立，**不构成对真实文档环境的普适安全保证**；对抗集同时显式记录了两类有意不拦的边界（文本混淆邮箱、非 Luhn 数字串）。

4.2 识别与精验流水线

识别采用两段式：正则 R_e 负责召回，程序化校验器 V_e 负责精确，实体 e 被判定为敏感当且仅当 $e \in R_e \wedge V_e(e)$ 。校验器针对不同实体类型实例化：手机号归一化后须恰为 11 位、银行卡须过 Luhn、身份证须过 GB11643 校验位（可选）、15 位证须命中地区码或触发词、人名须"姓氏表 $\cap$ 角色触发词窗口"。覆盖 20+ 类实体并按 GB/T 35273 思想做三级数据分级。

4.3 密钥体系

映射表真实值经 Fernet（AES-128-CBC + HMAC-SHA256）加密： $\text{Enc}_k(\cdot)$ 。主密钥 k 由密钥管理器统一托管，Windows 下经 DPAPI 按当前用户账户包裹： $k_{\text{stored}} = \text{DPAPI}_{\text{user}}(k)$ ，磁盘仅存 k_{stored} ，密钥文件移出项目目录并收紧 ACL。由此将"能否解密"归约为"是否为该 Windows 登录用户"，构成持久化机密性的信任根。

4.4 威胁模型与攻击博弈

我们按攻击者能力定义四类对手，并以博弈方式刻画安全性。记脱敏-还原系统为 $\Pi = (A_k, D_k)$ ，敏感实体集 $\mathcal{E}(x)$ 。

对手	能力	对应防线
黑盒	仅观察出网文本 $\hat{x}$ 与模型输出（被攻破的模型服务方、链路窃听者）	机密性: $\hat{x}$ 无明文, 注入亦无法泄露未掌握数据
黑盒·主动	可对待处理文档植入内容（伪造占位符、注入越权指令）	还原不可伪造 (nonce); 指令不改变"模型看不到明文"
白盒	读取本地磁盘持久化文件（会话/审计/映射/向量库），但不在活动用户会话内	持久化机密: 真实值密文存储, 无 k 不可解
白盒·持钥	劫持当前 Windows 用户会话、可调用 DPAPI 取回 k	超出防护目标: 等价"用户本人", 是安全与可恢复性的既定边界

以出网泄露博弈为例: $\text{Exp}_{\Pi}^{\text{leak}}(\mathcal{D})$ 中, 对手从语料 $\mathcal{D}$ 取 x , 观察 $\hat{x} = A_k(x)$, 输出一个猜测值 e^* ; 若 $e^* \in \mathcal{E}(x)$ 则对手胜。机密性等价于 $\Pr[\text{Exp}^{\text{leak}} \Rightarrow 1] = 0$ 。还原劫持博弈 $\text{Exp}^{\text{hijack}}$ 中, 对手植入字面量占位符 p^* 诱导 D_k 将他人明文写入其可控输出, 成功概率受 nonce 空间界定。

5 攻击实验与结果

5.1 评测方法

我们实现可复现的攻防评测脚本 `privacy_eval.py`。语料为 13 篇合成办公文本, 注入 41 个敏感实体实例（覆盖国际前缀、全角、分段卡号、PEM/JWT、IPv6/MAC 等边界格式), 并含 17 个不应被误伤的业务数字负样本（版本号、日期、订单号、数量)。评测以第 4.4 节的博弈定义度量各性质, 全部数据为虚构。

5.2 总体结果

#	实验（威胁）	指标	结果
5.2.1	黑盒 · 出网泄露 Exp^{leak}	脱敏召回率 / 明文泄露	100% / 0 例
5.2.2	黑盒 · 误伤	业务数字误报率	0% (0/17)
5.2.3	可用性 · 往返	$D_k(A_k(x)) = x$ 正确率	100% (13/13)
5.2.4	黑盒主动 · 还原劫持 $\text{Exp}^{\text{hijack}}$	植入字面量劫持成功率	0 / 500 轮
5.2.5	黑盒主动 · 提示注入	模型可见上下文真实 PII 数	0
5.2.6	白盒 · 持久化扫描	落盘文件明文 PII 命中	0
5.2.7	白盒 · 审计预览	审计掩码后明文 PII 命中	0
5.2.8	白盒 · 无密钥还原	strict 模式是否泄露明文	否（保留占位符）

表 1 隐私防护攻防评测结果 (privacy_eval.py, 2026-10-03 安全加固后复测)

5.3 按类别的专项召回测试

为细粒度验证各类识别器的有效性，我们另针对 11 类实体分别构造专项样本（每类 1–4 例、共 25 例，含边界格式），与 5.1 的 41 实例语料相互独立。结果如下：

类别	召回	类别	召回	类别	召回
手机号	3/3	银行卡	2/2	金额	3/3
身份证	2/2	邮箱	2/2	IP 地址	2/2
API 密钥	2/2	人名	4/4	地址	2/2
JWT	1/1	口令字段	2/2	合计	25/25

表 2 11 类实体专项样本召回 (25 例，独立于表 1 的 41 实例语料)

关键结论：5.2.1 与 5.2.5 合起来构成核心保证——出网文本零明文，因此模型在信息论上无法被诱导泄露它从未接触的数据；5.2.4 证明还原环节不可被植入劫持（碰撞概率 $\leq 36^{-4}$ ）；5.2.6–5.2.8 证明即使攻击者拿走本地磁盘文件、在无密钥条件下也无法恢复明文。

局限：评测语料为合成样例，真实语料上的召回会因未覆盖的实体形态而下降；人名连续列举、依赖背景知识的属性组合重识别不在本机制保证范围内。评测脚本与结果 JSON 随仓库提供，可一键复现。




图 2 涉密指令实测：手机号 / 身份证号 / 邮箱在送模型前替换为占位符，回答中的占位符在本机还原为明文呈现（模型全程未接触真实值）

6 纵深防御与审计

隐私之外，智能体的物理副作用同样需要约束。系统对每个具备副作用的工具施加四层防御，并以哈希链审计全程留痕。

路径沙箱

对目标路径取 **realpath** 后以 **commonpath** 判定是否落在沙箱根内，先化解符号链接/junction；文件名强制 basename 化，杜绝 **../** 穿越；写盘前对"最终落点"再做一次 **realpath+commonpath** 二次校验，拦截目录内符号链接指向外部的跟随式越界；越界读写一律拒绝。

命令白名单

命令名须命中 {python, pip, git, echo}，经 shlex 解析为 argv 后以 **shell=False** 执行，并叠加两层校验：**参数级**拦截 shell 操作符、路径穿越与绝对系统路径；**子命令级**封堵图灵完备入口——python 仅允许执行沙箱内的 .py 脚本（**-c / -m** / 标准输入等内联代码一律拒绝），pip/git 仅允许只读子命令（install/download/clone/fetch 等会触发第三方代码执行或改动仓库的入口被拒绝），git 另拦截 **-c / --git-dir / --upload-pack** 等可绕过边界的开关。**V3.4.4 加固**：脚本路径 realpath 沙箱归属校验（符号链接/盘符相对路径越界拒绝）、子进程环境白名单（剥离密钥与内部变量）、审批弹窗脚本内容预览防盲签。**V3.4.5 加固**：执行置于 Windows **Job Object** 进程容器（句柄即杀，超时/退出终止整棵进程树；进程数上限 64），并新增**严格模式**开关直接禁用解释器（仅留只读命令）。仍属策略层控制 + 进程容器，不是完整 OS 级沙箱。

熔断审批

策略引擎（deny-by-default）判定的高危操作挂起后台线程，弹窗展示申请工具、目标路径与**即将执行的命令 / 即将写入的内容**（长内容可滚动核对），人工授权才放行；超时自动驳回并关闭残留弹窗，杜绝"死弹窗"误导。

哈希链审计

每条日志哈希 $h_i = \text{HMAC}_\kappa(h_{i-1} \parallel \text{entry}_i)$ ，篡改即校验失败；审计自身落盘前统一复用脱敏管线掩码，只存脱敏预览（见 5.2.7）。

链锚点（V3.4 加固）

链式哈希只能证明"中间没被改"，防不住两种攻击：**降级改写**（旧实现里"无 HMAC"标记是从文件里读的，抹掉它再用无密钥 sha256 重算整链即可通过校验）与**尾部截断**（删掉最近若干条，剩余链依然自治）。为此增加一枚 HMAC 锚点，固定"条数 + 链头 + 历史 legacy 前缀长度"，并放在**密钥旁边**（用户目录）而非审计目录内——与密钥同一个理由：不能与它保护的对象同盘，否则删掉锚点就重新不可发现。规则：legacy 条目只允许出现在锚定的历史前缀内、条数不得少于锚点、锚点位置链头必须一致；锚点缺失而链非空则判无效，由用户显式"重建锚点"确认（迁移/拷贝审计目录的合法场景）。**残余局限**：能同时改写用户目录的攻击者（≈本机已被完全控制）仍可连锚点一起重做——任何纯本地审计都挡不住这一层，故如实声明。

另有模式级防线：快速模式禁用一切写操作工具（只读安全），思考模式支持完整工具调用与可调推理深度。本地知识库采用"入库即脱敏"管线，向量库中只存占位符文本。




图 3 高危操作熔断审批弹窗（"待审内容"审阅区完整展示即将写入的内容，消除盲签；工具决策由受控脚本注入以保证可复现，审批、沙箱写入、审计均为真实执行）




图 4 审计黑匣子面板：统计概览 / 哈希链状态 / 事件筛选 / 报告导出

下图为实测：当智能体试图执行不在白名单内的系统命令（`tasklist`）时，先触发熔断审批，被驳回后如实向用户说明"由于涉及敏感操作，系统未能执行该命令"，全程未产生任何命令执行副作用。




图 5 命令白名单实测：非白名单命令（`tasklist`）被内核拦截，模型基于真实拦截结果如实反馈（工具决策由受控脚本注入，拦截与回答为真实链路）

脱敏 RAG 知识库（实测闭环）

机密文档"入库即逐块脱敏"，向量库中只存占位符；检索命中后，答案中的占位符在输出层还原为真实值呈现给用户。实机演示（外部算力 GLM-4.7 接入）：对已入库的《合同_隐盾项目.txt》提问，系统调用 `search_knowledge_base` 语义检索并在 **占位符形态**下交给云端模型作答（出网内容已脱敏），回答里的占位符由输出层在本机还原为真实值呈现给用户——**模型全程只见占位符，真实值仅在本机输出层出现**。该链路的自动化回归见 `tests/test_kb_pipeline.py` 与本地 E2E 实测

(`tests/test_e2e_local.py` , 含"检索工具被真实调用"断言)；**已知边界**：外部模型可能对未在映射表中的占位符（自行改写编号）无能为力，此时该片段以占位符原样显示。

入库顺序 (V3.4 修正)：必须先**整篇脱敏**、再**切块**。旧实现是"先切块、再逐块脱敏"，任何长于单块尺寸（500 字符）的实体——PEM 私钥、长连接串、大段 base64——会被切碎，碎片两边都匹配不到正则，于是**明文碎片进了向量库**。整篇脱敏后长实体已被单个占位符替换，再切块就不可能把它切碎；每块只保留"本块真的出现"的占位符映射，跨块还原不串值。同时，占位符解析正则补全了含下划线与数字的实体类型（ `MEDICAL_RECORD` / `IDCARD15` / `PRIVATE_KEY` / `ACCESS_TOKEN` 与插件实体 `PLUGIN_*` ），避免这些类型在检索重编号时被漏掉而导致跨文档串值；向量库元数据不再写入本机完整路径（只留文件名）。回归门禁： `tests/test_kb_pipeline.py` （纯文本管线，不依赖向量库与网络）。



图 6 本地知识库管理：文档已入库（入库即逐块脱敏），向量库零明文

7 安全工程闭环

我们以"红队—修复—回归"的方式持续加固：先对系统做对抗性安全测试（攻击用例动态验证 + 通读源码审查），输出分级问题清单，逐项修复并将对抗用例固化为回归测试。下表列出与安全内核强相关的核心问题及其修复与对应提交：

表 3 安全内核级问题与修复（节选，均可在 git 历史追溯；本表跨页，故表题置于表上方）

核心问题	危害	修复	提交
命令执行为 shell=True + 子串黑名单，可被 cmd/powershell 绕过	任意命令执行，沙箱形同虚设	白名单 + shlex + shell=False + 参数级纵深拦截	357907f
"沙箱"默认放行任意绝对路径，策略 default=approve	读桌面/写系统目录均被放行	realpath+commonpath 越界判定， deny-by-default	357907f
审批弹窗共用单一 Event，多工具待审时点一个=放行全部	审批旁路，高危操作绕过人工确认	逐请求审批 + 超时自动驳回 + 关闭残留弹窗	e17fd83
workflow 链路绕过隐私网关，合同原文直发云端	聊天侧脱敏在 workflow 侧失效，明文出网	所有 LLM 调用统一走 anonymize→invoke→deanonymize	357907f
审计日志在还原后记录，真实 PII 落盘	审计系统反成泄露源	落盘前统一掩码（复用完整脱敏管线）	a79645c
占位符格式固定可预测，可被植入字面量劫持还原	恶意文档诱导写出他人明文	随机 nonce + strict 还原不回退明文	a79645c
KeyManager 哈希链不覆盖 cipher_key	可静默替换密钥而完整性校验不报警	完整性字段纳入密钥材料	357907f
映射表明文 dict 落盘	拿到文件即还原全部真实隐私	Fernet 加密存储 + DPAPI 包裹密钥	9150bf9
审计工具结果接口参数顺序颠倒	成功的工具调用被误判为失败，链路中断	修正调用方 + 调用点静态扫描回归测试	e17fd83
人名识别漏当代高频大姓、5 位以上裸金额漏检	核心实体召回不足	姓氏/角色触发词补全 + 金额正则扩展 (评测复测召回 100%)	252202c
第二轮红队： 脱敏替换逻辑按"首次出现的相同子串"定位，而非正则命中位置	同串先在非敏感处出现时，敏感字段残留明文（确定性泄露）	改为按命中区间从右向左精确替换；捕获组取"首个真正参与匹配的分组"	121f420

核心问题	危害	修复	提交
第二轮红队： 命令白名单可被图灵完备入口穿透（ <code>python -c / -m / pip install / git -c</code> ）	无需 shell 元字符即可任意代码执行	新增子命令级校验：python 仅限沙箱内 .py 脚本；pip/git 仅限只读子命令；git 拦危险开关	121f420
第二轮红队： 审批弹窗只显示工具名与路径，不显示待执行内容	审批人看不到要执行的命令/写入内容（盲签）	弹窗渲染完整命令与写入内容（含字数与截断提示）	121f420
第二轮红队： 取消采用 <code>with ThreadPoolExecutor</code> ，退出时 <code>wait=True</code>	取消仅 UI 假象：后台仍占算力，旧信号污染新气泡	显式 <code>shutdown(wait=False)</code> + 断开该轮全部信号（回归实测 0.33s 返回）	121f420 / b0599e0
第二轮红队： 隐私回归用例阈值容忍 4 条已知泄露，且负样本与正样本自相矛盾	回归带病通过，泄露不被拦截	修复 4 条泄露根因，阈值 4→0、误伤 0；负样本按业务语义归位	121f420
第三轮自审： 知识库"先切块、再逐块脱敏"	长于单块尺寸的实体（PEM 私钥等）被切碎成明文碎片进入向量库	改为先整篇脱敏再切块（长实体已成占位符，切不开）；每块只存本块用到的映射	V3.4.0
第三轮自审： 占位符正则 <code>[A-Z]+</code> 漏掉含下划线/数字的类型	MEDICAL_RECORD / IDCARD15 / PRIVATE_KEY / ACCESS_TOKEN / PLUGIN_* 不参与检索重编号，多文档还原可能串值	正则补全类型字符集（下划线、数字）	V3.4.0
第三轮自审： 向量库元数据写入本机完整路径	落盘面泄露本机目录结构（且该字段从未被读取）	只存文件名；chunk id 改由文件名派生，哈希 MD5 → SHA-256	V3.4.0
第三轮自审： 审计"无 HMAC"标记从文件里读	抹掉该标记再用无密钥 sha256 重算整链即可通过校验（降级改写）；尾部截断亦不可发现	HMAC 链锚点（条数+链头+历史 legacy 前缀），存放于密钥旁的用户目录；legacy 仅允许出现在锚定前缀内；缺失锚点需显式重建	V3.4.0

核心问题	危害	修复	提交
复赛评审意见：命令执行允许 Python 等通用解释器，尚不构成严格执行沙箱	放行脚本以当前用户权限运行，可触达沙箱外资源	V3.4.4: 脚本 realpath 沙箱归属校验（符号链接/盘符相对路径拒绝）、环境收敛、审批弹窗脚本预览防盲签； V3.4.5: Job Object 进程容器（句柄即杀/进程数上限 64）+ 严格模式开关（禁用解释器）；并如实声明非 OS 级隔离	V3.4.4 / V3.4.5
复赛评审意见：附件全文存在明文持久化至会话文件的路径	与"关闭落盘泄露面"的表述不一致	V3.4.4: 附件快照 Fernet 密文段落盘 + 启动主动迁移存量明文 + 密文正向断言； V3.4.5: 删除会话即刻清除其附件快照，全目录明文扫描回归	V3.4.4 / V3.4.5
复赛评审意见：评测基于规模有限的合成样本，"100% 召回、零泄露"不宜泛化	安全结论被过度外推	V3.4.4: 对抗性评测集（格式变体/零宽插入/已知边界显式记录）+ 文档内限定口径； V3.4.5: 真实格式文档评测集（8 种格式全链路）	V3.4.4 / V3.4.5
V3.4.5 真实文档评测 新发现：脱敏后段规则命中先前占位符内部/跨越边界	交叉替换（如 [BANKC[ADDRESS_0_x]）使真实值不可还原、还原内容错乱	占位符对后续规则不透明（仅在非占位符片段上匹配，含插件识别器区间保护）；银行卡尾部不再吞换行；回归断言"脱敏→还原逐字一致"	V3.4.5

8 测试与质量保障

项目建立 20 个测试套件（另有 `test\_e2e\_local.py` 本地大模型端到端实测，需 YINDUN_E2E=1 显式开启），覆盖隐私引擎、审计哈希链（含链锚点）、记忆管理、工作流引擎、知识库文本管线、插件体系（宿主契约 + 能力端到端 + laya 风险分级插件）、闪发折叠窗口几何与攻防评测（第 5 节），并把三轮自审 + 复赛评审整改中发现的问题全部固化为回归用例。全部套件退出码 0（"知识库"为集成测试，需本地 Ollama 在线，不在线时明确标注跳过而非误报失败）。

测试套件	覆盖范围	结果
privacy_eval（攻防评测）	黑盒/白盒/劫持/注入/无密钥 9 项实验	✅ 全部达标
privacy_audit_test（隐私回归）	46 项正样本脱敏 + 18 项负样本零误伤 + 落盘明文扫描	✅ 泄露 0 / 误伤 0（阈值 0）
test_command_whitelist	16 项高危命令入口必须拦截 + 3 项只读用法必须放行	✅ 16/16 拦截
test_worker_cancel	慢速模型下取消必须立即返回（不等待在途请求）	✅ 0.33s（模型需 5s）
test_privacy_engine	实体识别/脱敏/还原/nonce/strict/接口兼容	✅ 6/6 + 3 项专项
test_audit_log	哈希链/防篡改/调用点一致性扫描 + 链锚点（降级改写、尾部截断、锚点改写均须被识破）	✅ 19/19
test_memory_optimize	摘要压缩/跨轮还原/序列化	✅ 6/6
test_plugins（V3.4 新增）	插件宿主契约：钩子分类与禁用能力黑名单、manifest 校验、依赖门禁、启停持久化、载荷净化（越界/超长/跨行/重叠丢弃）、配置读写越界拦截、自检	✅ 全部通过
test_plugin_capabilities（V3.4 新增）	能力端到端：补充识别进入脱敏并计入审计、停用即收回；插件模板高危步骤被强制人工审批、不可覆盖内核模板；插件解析优先且内核格式不被顶替；插件导出渲染 + 内核格式兜底；能力变更留痕	✅ 全部通过
test_laya_risk（新增）	内置插件 laya 风险分级：requires 留空可无 laya 启用；无模型时自动回退正则规则（删除/格式化→高危、写入/外发→中危、只读→低危）；规则文件热改生效、非法行跳过并告警；backend.txt 强制模型/正则；stub 验证模型打分与推理失败回退；停用即收回、自检	✅ 全部通过

测试套件	覆盖范围	结果
test_privacy_adversarial (V3.4.4 新增)	隐私对抗集：分隔符/全角/国际区号/ 零宽字符插入 /结构化上下文（JSON/ 表格/CSV）等 14 项格式变体必须命 中；订单号/日期/版本号等 6 项负样本 零误伤；"(at) 文本混淆"与"非 Luhn 数字串"作为 已知边界 显式记录并与声 明一致	✅ 全部通过
test_privacy_docs_eval (V3.4.5 新增)	真实格式文档评测： txt/md/csv/html/eml/docx/xlsx/pdf 8 种真实格式 走完整解析链路（解析 → 风险报告与正文分离 → 脱敏 → 还 原 → 送模型上下文 → 会话落盘扫 描），断言正文与报告中的部分掩码片 段（如 138****5678）不进入模型上 下文、业务数字零误伤；并含 占位符 不透明性回归 （脱敏→还原逐字一 致，随机 nonce 多次采样）	✅ 全部通过
privacy_audit_test 增补 (V3.4.5)	占位符不透明性回归：后续规则命中 占位符内部/跨越边界即判失败（曾致 真实值不可还原），随机 nonce 采样 180 轮	✅ 往返逐字一致
test_kb_pipeline (V3.4 新增)	知识库文本管线（不依赖向量库/网 络）：占位符类型解析（含下划线/数 字/PLUGIN_*）、长实体先脱敏后切块 不被切碎、分块映射隔离、元数据无 本机路径	✅ 全部通过
test_workflow / test_knowledge_base	工作流/审批链/入库检索/向量库零明 文	✅ 通过（知识库需 Ollama 在线）

表 4 测试套件汇总（2026-10 复赛评审整改后复测，共 20 个套件）




图 8 设置面板：对话模型选择、隐私与权限（含新增「允许执行本地脚本」严格模式开关）、深度思考强度与权限等级

9 结论与展望

隐盾把"让大模型安全地处理涉密办公数据"从使用约定下沉为架构约束：以内存级脱敏网关关闭出网与落盘泄露面，以沙箱/白名单/熔断审批约束物理副作用，以哈希链审计实现可追溯且自身不泄露，并以可复现的攻防实验量化了隐私防护效果（自建评测集上黑盒召回 100%、明文泄露 0、还原劫持 0、白盒持久化 0 命中；另有格式变体对抗集与"已知边界"清单——该结论仅对评测集成立，不泛化为真实环境安全保证）。核心问题均以 git 提交与回归测试留痕，形成"发现—修复—验证"的工程闭环。

同一约束也决定了扩展方式（V3.4）：判定权留在内核、能力开放给插件，插件只能扩大保护范围或增加可用性，不能缩小保护范围——这让系统可以持续长大，而"安全"不随扩展而稀释。

下一步

- 引入 NER 模型补充规则式识别，提升开放域实体召回；
- 工具调用结果文件系统侧二次核验，杜绝小模型幻觉式"假成功"；
- 审计链头外部锚定，抵御整体重算哈希链；
- 在更大真实语料上扩展攻防评测，量化召回—误报权衡曲线，并引入差分隐私式度量作为补充。

本文档中的个人信息（张伟、13812345678 等）均为公开测试样例，不涉及任何真实个人数据。评测与截图取自真实运行环境（Windows 11 · RTX 3060 Ti · Ollama qwen2.5-7b / GLM-4-Flash 双算力）。